



Predição da Qualidade de Vinhos com Machine Learning

DESAFIO



A classificação da qualidade dos vinhos depende, atualmente, de análises sensoriais especializadas, um processo essencial, porém custoso, demorado e sujeito à subjetividade humana.

OPORTUNIDADE



Os processos produtivos já geram uma grande quantidade de dados físico-químicos.

Esses dados podem prever a qualidade final do vinho antes da avaliação dos especialistas?

PROPOSTA

Utilizar modelos de machine learning para monitorar os atributos do vinho, prevendo quais lotes atingirão o padrão de alta qualidade.



Maior previsibilidade da qualidade dos lotes



Apoio à tomada de decisão baseada em dados



Redução de custos de inspeção



Maior padronização do controle de qualidade

BASE DE DADOS


A análise foi realizada sobre 1.143 amostras de vinho, contendo 11 características físico-químicas coletadas durante o processo produtivo e utilizadas como variáveis preditoras da qualidade.

Qualidade dos Dados e Desafios da Modelagem

A base apresentou características adequadas para a construção do modelo, fornecendo informações consistentes sobre o processo produtivo.

O principal desafio era identificar os vinhos de Alta Qualidade, que representam apenas 13,9% da amostra, exigindo uma abordagem capaz de distinguir corretamente os lotes com maior potencial.

Proporção de vinhos por classificação



COMPARAÇÃO DOS MODELOS TESTADOS

Critérios	Regressão Logística	XGBoost / Gradient Boosting	Random Forest
Robustez a ruídos	Alta	Média	Alta
Interpretabilidade	Alta	Média	Boa
Capacidade preditiva	Média	Elevada	Elevada
Estabilidade dos resultados	Boa	Variável	Excelente
Complexidade de Implementação	Baixa	Alta	Média
Adequação ao Problema	Parcial	Boa	Excelente

Processo de Seleção

Foram avaliadas diferentes abordagens de Machine Learning utilizando a mesma estratégia de treinamento e validação.


Os modelos foram comparados quanto ao desempenho, robustez e estabilidade dos resultados.

O Random Forest apresentou o melhor equilíbrio entre esses fatores e foi selecionado como modelo final.

RESULTADOS DO RANDOM FOREST

O modelo foi capaz de diferenciar com elevada precisão os vinhos de alta e baixa qualidade, segmentando as amostras conforme o potencial identificado nos dados.

ZONAS DE DECISÃO DO MODELO



DESEMPENHO DO MODELO

Zona de Alta Qualidade 11 sinalizados 10 realmente bons Ação: priorizar avaliação e comercialização premium.	91%
Zona Potencialmente Promissora 21 sinalizados 8 confirmados como bons Ação: enviar para análise complementar.	38%
Zona de Qualidade Comum 140 sinalizados 134 corretamente comuns Ação: menor prioridade para avaliação especializada.	96%

O QUE MAIS INFLUENCIOU AS CLASSIFICAÇÕES



Acidez volátil

Principal fator associado à redução da qualidade.

À medida que a acidez volátil aumenta, a nota do vinho tende a diminuir.

Foi uma das variáveis mais relevantes para diferenciar vinhos de alta e baixa qualidade.



Teor alcoólico

Maior associação positiva com a qualidade.

Os vinhos de Alta Qualidade apresentaram, em média, teor alcoólico superior aos demais.



Sulfatos

Importante indicador de estabilidade química.

Os vinhos de maior qualidade apresentaram níveis mais elevados de sulfatos, indicando uma relação positiva com a qualidade final.

COMO O MODELO TOMA DECISÕES?

O Random Forest analisou simultaneamente todas as características físico-químicas dos vinhos para realizar suas classificações.

Entre as variáveis avaliadas, teor alcoólico, acidez volátil e sulfatos foram as que mais contribuíram para distinguir vinhos de alta e baixa qualidade.


Esses fatores explicam grande parte das decisões apresentadas pelo modelo nos resultados anteriores.

IMPACTO PARA O NEGÓCIO

A solução transforma a triagem dos vinhos em um processo mais eficiente, priorizando os lotes com maior potencial de qualidade para avaliação especializada.

GANHO OPERACIONAL

O modelo atua como uma triagem inicial, organizando os vinhos por probabilidade de Alta Qualidade e direcionando a avaliação especializada para os lotes mais promissores.



Resultado prático observado

91% precisão na Zona de Alta Qualidade

96% precisão na Zona de Qualidade Comum

BENEFÍCIOS PARA A EMPRESA

Maior eficiência operacional

Reduz o volume de análises manuais ao concentrar a avaliação especializada nos vinhos com maior potencial de qualidade.

Melhor alocação dos especialistas

Direciona o tempo da equipe de qualidade para os lotes mais promissores e de maior valor agregado.

Decisão baseada em dados

Complementa a avaliação sensorial com indicadores objetivos, tornando o processo de decisão mais padronizado e consistente.

Produtividade na certificação

A triagem automatizada acelera o processo de seleção e reduz avaliações desnecessárias em lotes de menor potencial.

CONCLUSÃO

O projeto demonstrou que características físico-químicas podem antecipar a qualidade dos vinhos com elevado grau de confiabilidade, permitindo uma seleção mais produtiva, consistente e orientada por dados.



Predição da Qualidade de Vinhos com Machine Learning

FIM

<https://www.youtube.com/watch?v=2fsMiUjdruw>